

針對 IoT 異常檢測之自適應語意通訊系統設計 與分析

指導教授： 王和盛

學生： 傅柏譯(學號 0126C047)

楊喬閔(學號:01281019)

海洋大學通訊系 4A

摘要

本研究建構了涵蓋發射端、通道與接收端的完整通訊架構。在發射端，系統會先篩選出異常的感測器數值，並於數值後附加其英文拼寫（例如 2.95 附加 two point nine five）作為語意冗餘保護機制；通道層則採用 AWGN 模型搭配 BPSK 調變，模擬 1.0 dB 至 5.0 dB 之間的惡劣干擾環境。在接收端，本專題設計了「字串演算法搭配 LLM」的雙軌解碼機制：系統會優先使用 Python 全域滑動視窗 (Global Sliding Window) 進行字串相似度比對，並以 0.70 作為算力切換門檻，若因雜訊過大導致比對失敗，才會改由 LLM 根據上下文進行判斷與數值修復。此機制有效防止了 LLM 在高雜訊時容易產生「幻覺 (hallucination)」的問題。實驗結果顯示，於 $E_b/N_0 = 3.0$ dB 時，系統之平均相對誤差可降至 0.09 以下，感測器命中率達 96.3%，且 JSON 格式輸出成功率維持 100%。

此外，本系統具備良好的跨資料集適應能力（泛化能力）。由於系統在執行時，會動態掃描並讀取資料集內的感測器名稱作為比對字典，因此完全不需重新訓練或微調模型，即可直接應用於不同的工業場景（例如：引擎預測性維護資料與水質監測資料），展現出在工業物聯網部署上的高度彈性。本研究之完整實驗程式碼（包含資料集生成、模型微調與端到端測試管線）與量化模型權重，已全數開源發布於 GitHub 供學術驗證，專案網址：<https://github.com/Boyifu/6G-Semantic-Communication-IoT>

壹、緒論與研究動機

隨著 6G 技術的演進，海量物聯網（mIoT）已成為工業自動化與預測性維護的關鍵基礎。然而在工廠等高雜訊物理環境中，傳統數位通訊系統往往需仰賴高複雜度的通道編碼以維持可靠度，導致頻寬大量耗損；若無差別地導入深度學習於訊號處理，亦將為邊緣設備帶來沉重的運算負擔。

為突破上述瓶頸，本計畫提出一套兼具高容錯率與強健性的「端到端語意通訊系統」，在不使用前向錯誤更正碼（FEC）的前提下，以大型語言模型（LLM）承擔語意層之錯誤修復，實現高效的工業感測數據傳輸。本研究期望透過雙軌解碼之機制，在降低邊緣設備運算消耗的同時，仍能確保工業感測數據的精準還原，以解決傳統通訊架構在惡劣干擾環境下之侷限性，為未來的物聯網部署提供具備高度彈性之解決方案。

貳、文獻回顧

傳統通訊系統的設計長期受限於夏農定律 (Shannon's limit)，高度仰賴位元層級的精準度與複雜的通道編碼技術。然而，隨著 6G 網路時代的來臨，通訊典範正逐漸向語意通訊 (Semantic Communication) 轉移。探討大型語言模型 (LLM) 在不具備理想通道條件下如何維持通訊可靠度，已成為近年學術界的關注焦點。

一、大型語言模型於實體層之應用

在過去，非語言的神經網路架構(如 DeepSC)常被用於語意萃取與編解碼。然而，研究證實了 LLM 直接介入實體層通訊的潛力。Wang 等人 (2025) 提出了一套名為 LLM-SC 的語意通訊框架，將大型語言模型直接應用於物理層的編碼與解碼過程。他們的研究結果顯示，在完全不使用前向錯誤更正碼 (FEC) 等傳統通道編碼的情況下，LLM-SC 依然能於位元錯誤率 10^{-3} 時帶來約 8 dB 的編碼增益。此外，當訊噪比 (SNR) 超過 3 dB 時，其語意效能即超越傳統的 DeepSC 模型，並可於高訊噪比下達成零語意誤差之傳輸。這項研究為捨棄傳統通道編碼、直接利用語言模型對抗實體層雜訊提供了理論基礎。

二、接收端之語意錯誤修正

針對 6G 網路中的擴增實境與虛擬實境等沉浸式應用，Zhang 等人 (2025) 提出了整合多模態大型語言模型 (MLLM) 的語意通訊框架 MLLM-SC。該研究強調，在資源受限的無線通訊系統中，必須透過設備與邊緣伺服器的協同架構來處理高維度的多模態數據。MLLM 能夠在邊緣端分析多模態輸入與使用者意圖，並生成「重要性感知 (Importance-aware)」的注意力熱圖，藉此引導語意編碼器根據通道狀態動態分配頻寬。此概念證明了透過大型模型掌握上下文，能有效優先處理具備高語意價值的資訊，進而在有限頻寬下維持高質量的內容重建與生成。

三、AI 原生 6G 網路之邊緣部署與評估準則

隨著通訊系統轉向傳輸任務相關的意義，傳統的位元錯誤率 (BER) 已無法全面衡量語意通訊的真實效能。Kamath 等人 (2026) 的研究指出，未來的 AI 原生 6G 網路應著重於「意義層級的重建誤差 (Meaning-level reconstruction error)」。

此外，該研究點出了一個關鍵的部署瓶頸：標準的大型語言模型由於記憶體足跡與能耗過大，完全不適用於 6G 邊緣用戶設備與物聯網 (IoT) 裝置。因此，必須透過模型壓縮技術開發「微型語言模型 (TinyLMs)」，才能將 LLM 等級的語意編碼能力橋接至嚴苛的邊緣硬體限制中。在數值與語意並重的工業通訊場景中，系統的損失函數與評估指標必須同時兼顧整體句構的完整性以及關鍵數值的絕對偏差。

四、本研究之切入點

儘管上述文獻證實了 LLM 應用於 6G 通訊的巨大潛力，但在實際的工業物聯網 (如感測器數值監測) 應用中，純粹依賴 LLM 進行語意解碼極易產生「數值幻覺 (Hallucination)」，進而捏造出不存在的特徵名稱。為彌補現有研究中純 LLM 通訊架構在精確數值重建上的缺陷，本研究結合了傳統字串比對演算法與 LLM 結構化生成技術，提出一套「雙軌語意解碼機制」，並採用 BERTScore 與相對誤差百分比 (Relative Error) 之雙指標進行系統評估，期望能進一步推進高可靠度語意通訊在極端雜訊環境下之實際應用。

參、系統架構與流程

本系統之語意通訊架構分為發射端、物理通道與接收端三部分。

一、發射端(Transmitter)

發射端在取得數據後會先進行動態特徵載入與門檻式異常偵測，系統載入工業感測器資料庫，並自動計算各數值特徵的 5% 至 95% 分位數以建立「正常安全邊界」。當感測器數值突破此邊界時，系統將判定為異常數據，並針對偏離中位數比例最高之感測器優先進行傳輸。並採用「語意冗餘編碼 (Semantic Redundancy)」。發射端會將異常的阿拉伯數字轉換為英文字串(例如：將數值 2.95 編碼為 2.95 (two point nine five))。將脆弱的浮點數與具備邏輯關聯的單字綁定，為接收端的大型語言模型提供語意修復線索。

二、物理通道(Channel)

本系統於實體層嚴謹實作了基頻通訊模擬。首先，發射端之語意冗餘字串會透過 UTF-8 編碼轉換為二進制位元串流，並採用二元相位偏移調變 (BPSK) 映射為 +1 與 -1 之實體層符號。

接著導入加性高斯白雜訊 (AWGN) 通道模型。實驗設定了 E_b/N_0 介於 1.0 dB 至 5.0 dB 之嚴苛訊噪比區間。另外當極低訊噪比導致位元嚴重翻轉、產生無法對應有效 ASCII 碼的控制字元時，系統會強制將其替換為未知符號 (?)，模擬資料包在惡劣通道中產生的亂碼、字元遺失或錯位現象。

三、接收端(Receiver)

LLM 在高雜訊環境下容易捏造不存在之感測器特徵，為解決問題，我們在接收端加入「全域滑動視窗（Global Sliding Window）搭配 LLM 結構化生成」雙軌語意解碼

1. 全域滑動視窗（Global Sliding Window）

接收端獲取雜訊字串後，系統不會直接信任 LLM 的推論。系統會動態萃取資料庫中所有合法的感測器名稱作為標準字典。接著，系統以非字母字元過濾後的純文本進行「全域滑動視窗」掃描，計算雜訊字串與合法名稱的最高相似度。當最高相似度達到門檻值 0.70 以上時，系統即鎖定該感測器名稱。

2.LLM 解碼

當通道環境惡劣，導致接收字串破碎至全域最高相似度低於 0.70 時，系統將退回信任 LLM 推論結果。此時，受損的冗餘字串將送入大型語言模型。透過預先設計的少樣本提示（Few-Shot Prompting），系統強制 LLM 讀取括號內的英文殘篇進行小數點與數值之對齊還原。同時啟用 JSON Mode，限制 LLM 輸出格式穩定的 JSON 結構。




圖 3-1 系統流程圖

肆、實驗環境與評估指標

為驗證本專題所提出之「語意通訊系統」在極端通訊環境下的數值修復能力，本章將說明系統的軟硬體實驗環境配置、大型語言模型（LLM）的微調（Fine-tuning）策略，以及驗證階段所採用的指標與資料集設計。

硬體與模型	詳細規格與參數
運算硬體平台	Google Colab
圖形處理器 (GPU)	T4 GPU
微調與部署框架	Unsloth
基礎語言模型	Llama 3 8B (unsloth/llama-3-8b-bnb-4bit)
量化技術 (Quantization)	4-bit 量化載入
最大上下文長度 (Max Seq Length)	2048 Tokens
LoRA 秩 (Rank)	16
LoRA 縮放係數 (Alpha)	32
LoRA 隨機失活 (Dropout)	0
目標更新模組 (Target Modules)	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj
隨機種子(Random State)	3407
輸出模型格式	GGUF (q8_0 量化)

表 4-1 硬體與模型

訓練超參數	數值與設定
訓練總輪數 (Epochs)	3
批次大小 (Batch Size)	2 (Per Device)
梯度累積步 (GradientAccumulation)	8
學習率 (Learning Rate)	2×10^{-4}
學習率排程器 (LR Scheduler)	Cosine
暖身比例 (Warmup Ratio)	0.1
權重衰減 (Weight Decay)	0.01
優化器 (Optimizer)	AdamW (8-bit)
訓練樣本結構	Alpaca 格式 (Instruction / Input / Response)

表 4-2 訓練超參數

資料集與通道	參數與說明
SFT 訓練集來源	自行建構之工業物聯網知識圖譜
訓練集總筆數	2500 筆
訓練集涵蓋領域	電氣、流體、機械、熱力學
訓練集雜訊通道模擬	二元對稱通道 (BSC)
訓練集位元錯誤率 (BER)	0.01 至 0.06
測試集 1	Predictive Maintenance Dataset (Hugging Face 公開資料集)
測試集 2	Water Potability Dataset (Hugging Face 公開資料集)
基頻調變技術	二元相位偏移調變 (BPSK)
測試通道干擾模型	加性高斯白雜訊 (AWGN)
訊雜比 ($\frac{E_b}{N_0}$) 測試區間	1.0dB 至 5.0dB

表 4-3 資料集與通道

一、訓練集樣式

為使模型適應特定任務，本實驗採用 Alpaca 格式建構訓練集，包含指令 (Instruction)、帶雜訊之輸入 (Input) 與標準 JSON 輸出 (Output)。圖 4-1 為單筆訓練樣本之資料結構範例：

```

"instruction": "You are a 6G Semantic Decoder in an Industrial IoT environment."
"input": "ERR3({xhau0t_GAs0Tump_C 623 (siX hwm dped afd$t7elpq dhree)",
"output": "{\`status\`: \`ERR\`, \`sensor\`: \`Exhaust_Gas_Temp_C\`, \`value\`: 623}"

```

圖 4-1 訓練集樣式

二、測試集樣式

為驗證本專題所提出之語意接收機在未見過之真實數據上的泛化能力 (Generalization)，本系統於端到端測試階段改採開源之真實世界工業與環境監測資料集進行評估。

本實驗選用 Hugging Face 平台上具代表性的兩套資料集：預測性維護資料集 (Predictive Maintenance Dataset) 與水質檢測資料集 (Water Potability Dataset)。測試過程中，系統將此兩類資料集之原始浮點數與整數參數進行基頻調變，並導入加性高斯白雜訊 (AWGN) 通道 (測試區間設定為 $\frac{E_b}{N_0} = 1.0\text{dB}$ 至 5.0dB)，藉此評估模型對於不同物理量之極端雜訊修復表現。測試集之核心特徵摘要如圖所示。

資料集名稱	涵蓋之物理感測器 參數與型態	驗證情境與目的
Predictive Maintenance	Engine rpm Lub oil pressure Fuel pressure Coolant pressure Lub oil temp Coolant temp	模擬工業與機械加工環境中，動態馬達參數因通道干擾受損時的修復穩定性。
Water Potability	pH Hardness Solids Chloramines Sulfate Conductivity Organic_carbon Trihalomethanes Turbidity	模擬環境監測與流體輸送管線中，連續性物理量參數在無前向錯誤更正碼 (FEC) 情況下的解碼精確度。

表 4-4 測試集樣式

測試集之原始數據皆取自開源社群 Hugging Face，詳細來源連結如下，以確保實驗數據之公開可溯性：

1. 預測性維護：[\[https://huggingface.co/datasets/MohammedSohail/predictive-maintenance-dataset\]](https://huggingface.co/datasets/MohammedSohail/predictive-maintenance-dataset)
2. 水質檢測：[\[https://huggingface.co/datasets/DarkNeuronAI/water-potability-3k\]](https://huggingface.co/datasets/DarkNeuronAI/water-potability-3k)

三、跨通道模型之泛化驗證與理論等效

本研究在監督式微調（SFT）階段採用二元對稱通道（BSC）進行均勻隨機的位元翻轉訓練；然而在測試階段，卻改採加性高斯白雜訊（AWGN）搭配 BPSK 調變之硬判決錯誤進行驗證。此「訓練與測試通道不一致」之設計為驗證本系統之「跨通道泛化能力」。

在真實通訊場景中，雜訊型態往往因多路徑衰落或突發干擾而高度複雜。BSC 的錯誤為純粹的均勻隨機分佈，而 AWGN 的硬判決錯誤則與瞬時振幅高度相關（易產生連續錯誤）。若 LLM 僅是死背特定的錯誤樣態，勢必無法在未見過的 AWGN 通道中生存。因此，本研究藉由跨通道測試，證實本系統之修復能力來自於對底層語意與上下文冗餘的理解，而非單純的樣式記憶。

此外，為確保兩者在干擾強度上具備客觀的比較基準，本研究導入了 BPSK 於 AWGN 通道下之理論位元錯誤率（Theoretical BER）公式進行等效映射：

$$P_b = \frac{1}{2} \operatorname{erfc}\left(\sqrt{\frac{E_b}{N_0}}\right)$$

依據公式計算，本測試階段設定之 $\frac{E_b}{N_0}$ 區間（1.0 dB 至 5.0 dB）與其等效之 BER 對照如下：

$\frac{E_b}{N_0}$	BER
1.0dB	0.05628
2.0 dB	0.03751
3.0 dB	0.02288
4.0 dB	0.01250
5.0 dB	0.00595

表 4-5 映射對照表

由表 4-5 可知，測試環境之等效位元錯誤率（0.0060~0.0563）與 SFT 訓練集設定之干擾區間（BER = 0.01 ~ 0.06）高度吻合。此外，針對訓練集未涵蓋極低錯誤率（如 BER < 0.01）之設計，係基於模型正規化之考量：藉由屏除趨近完好之乾淨樣本，可有效避免模型產生過度擬合（Overfitting）。

四、評估指標定義

由於不同感測器的物理尺度差異大，本系統採用「**相對誤差 (Relative Error)**」進行評估，即將絕對誤差除以真實值進行正規化，其定義為 $Rel\ Err = \min(\frac{|\hat{y}-y|}{|y|}, 1.0)$ ，最終取所有樣本之平均值。此外，當預測數值偏離真實值超過 100%，系統一律給予上限為 1.0 的誤差，確保單一極端失誤不致過度放大整體平均誤差。

為驗證系統在極端惡劣通道中之語意辨識能力與格式防護力，本研究額外定義了兩項鑑別度指標：

感測器命中率 (Sensor Accuracy)：評估系統(包含全域滑動視窗與 LLM)是否能從受損、破碎的雜訊字串中，正確對齊並識別出原始發射的感測器特徵名稱。

JSON 格式成功率 (JSON Success Rate)：評估大型語言模型在極端雜訊干擾下，是否仍能穩定輸出符合規範之 JSON 結構。

伍、結果展示與分析

本章旨在驗證語意通訊系統於不同雜訊強度下之解碼與修復效能。分析將從實體層之訊號衰落特徵開始，接續探討系統整體的相對誤差與語意相似度表現，最後針對極端環境下之高誤差樣本進行分析。為確保系統效能評估之客觀性，本章在計算數值誤差時未剔除任何極端離群值，而是將嚴重失效之樣本賦予最高為 1.0 之相對誤差，並全數納入整體平均計算。

一、不同訊雜比下之 BPSK 時域波形衰落對比




圖 5-1 不同訊雜比下之 BPSK 時域波形

為突顯語意解碼在惡劣通道中之必要性，本節針對二元相位偏移調變（BPSK）在不同加性高斯白雜訊（AWGN）強度下之時域波形進行物理層觀測。由圖 5-1 可知，在極端惡劣環境（ $\frac{E_b}{N_0} = 1.0$ dB）下，接收端訊號（紅線）受雜訊嚴重干擾，其振幅劇烈震盪並頻繁跨越零點。此現象證實了傳統實體層硬決策（Hard Decision）在該環境下必然產生大量位元翻轉（Bit Flip），導致字元嚴重毀損。隨著訊雜比提升至 5.0 dB，雜訊震盪幅度顯著收斂並貼合原始方波（綠線）。此衰落特徵印證了本系統所建構之通訊物理環境符合真實通道模型，並凸顯了後端導入語言模型進行數值修復之必要性。

二、滑動視窗門檻值最佳化分析




圖 5-2 門檻值分析

為驗證本研究中「全域滑動視窗」門檻值設定之合理性，本節於訊雜比 $E_b/N_0 = 1.5$ dB 之環境下，針對 0.5 至 0.9 之門檻值進行系統平均相對誤差掃描測試。實驗結果顯示，當門檻值過低時(如 0.5 和 0.6)，系統放寬匹配標準，導致大量受損字串被錯誤識別為不相關之感測器，產生嚴重之誤判，使系統整體 MAE 攀升至 0.9 左右。反之，當門檻值過於嚴苛(如 0.9)時，幾乎所有受損樣本皆被強制交由大型語言模型(LLM)處理，此舉除了導致運算資源之浪費外，在極端雜訊環境下，龐大的純雜訊字串亦會提高 LLM 發生「幻覺」之機率，導致 MAE 微幅回升。

由實驗結果可知，雖然相似度門檻設定於 0.80 時，系統整體相對誤差達到最低點，但相較於門檻值 0.70，其 MAE 僅微幅下降約 0.02。在邊緣運算(Edge Computing)之實際應用場景中，硬體算力與功耗極其珍貴；若為追求微小之誤差改善而將門檻提升，將導致過多樣本被推入運算成本高的 LLM 進行推論。因此，基於「解碼精準度」與「邊緣算力消耗」之折衷考量，門檻值 0.70 處已呈現出顯著之誤差收斂與邊際效益遞減轉折。故本系統最終選定 0.70 作為雙軌切換之最佳超參數，以在通訊可靠度與硬體資源間取得最佳平衡。

三、系統整體效能：跨資料集之泛化與修復表現

本實驗分別針對預測性維護與水質檢測兩套不同之公開資料集進行端到端泛化測試 (Zero-Shot)。為確保實驗數據之統計公正性，並徹底消除大型語言模型生成隨機性所導致之非單調誤差波動，本研究採取以下設定：(1) 於每個 $\frac{E_b}{N_0}$ 測試點皆獨立取樣 100 筆異常特徵進行測試 (2) 強制鎖定全域隨機種子 (Random Seed = 42) 並將 LLM 推論溫度設為 0.0 (3) 所有測試皆進行 3 次獨立抽樣計算平均值，並於圖表中標示標準差誤差棒 (Error Bars)。在效能評估方面，系統採用平均相對誤差 (Relative Error，紅線) 評估數值還原精準度，並以感測器命中率與 JSON 格式成功率，精準評估系統之語意辨識力與格式穩定度。

訊雜 比 $\frac{E_b}{N_0}$	預測性維護 (MAE)	預測性維護 (Sensor Acc)	水質檢測 (MAE)	水質檢測 (Sensor Acc)
1.0dB	0.416782	0.783333	0.395126	0.720000
2.0dB	0.242478	0.906667	0.191979	0.860000
2.2dB	0.190255	0.943333	0.139985	0.903333
2.4dB	0.174449	0.960000	0.103773	0.946667
2.6dB	0.123546	0.966667	0.118611	0.926667
2.8dB	0.107550	0.963333	0.083447	0.946667
3.0dB	0.083409	0.983333	0.068281	0.966667
3.5dB	0.036532	0.996667	0.028879	0.980000
4.0dB	0.035160	0.996667	0.018063	0.986667
5.0dB	0.000020	1.000000	0.006690	0.993333

表 5-1




圖 5-3

四、消融實驗與多模型對比分析




圖 5-4

為進一步驗證「雙軌語意解碼架構」之必要性與效能優勢，本研究進行了消融實驗，對比了雙軌系統 (Dual-Track)、純全域滑動視窗 (GSW Only)、純大型語言模型 (LLM Only) 以及傳統之 Hamming(7,4) 通道編碼。如圖 5-4 所示，本研究所提出之雙軌制 (紅線) 在各個訊雜比下皆展現最低的系統誤差，並在低訊雜比區間顯著超越傳統通道編碼 (綠線) 與純大型語言模型解碼 (藍線)。

五、高誤差樣本分析

為進一步探討系統在突破物理極限時之失效模式，本研究於 $\frac{E_b}{N_0} = 1.0 \text{ dB}$ 至 2.0 dB 區間，針對預測誤差超過 50% 之邊界案例進行分析。表 5-2 列舉了最具代表性之三種高誤差樣態，其失效原因主要可歸咎於「小數點特徵遺失」以及「全域滑動視窗匹配失效」。需說明的是，本節所列樣本係人工挑選之代表性案例，並非依固定準則窮舉，僅用以說明失效型態。

訊雜比 $(\frac{E_b}{N_0})$	實驗數據紀錄	錯誤分析
2.0dB	原始正確發射: ERR: Fuel_pressure 2.0(two) 接收端收到雜訊: E?R:?Fuel]pr?ssUre 2???hpww) LLM 解碼 JSON: {'status': 'ERR', 'sensor': 'Fuel_pressure', 'value': 200.0}	英文字 two 遭雜訊完全毀損，LLM 雖然抓到數字 2，但因缺乏語意冗餘對齊，誤將其推論為 200.0。
2.0dB	原始正確發射: ERR: Fuel_pressure 16.19 接收端收到雜訊: ERR:""?elOprgsstve q6.19?(syxteen4point one nife) LLM 解碼 JSON: {'status': 'ERR', 'sensor': 'Engine_rpm', 'value': 16.19}	數值部分與小數點完美還原，但 Fuel_pressure 之字元在通道中受損過重，導致 LLM 誤判為 Engine_rpm。
2.8dB	原始正確發射: ERR: Engine_rpm 388.0 接收端收到雜訊: ERR: Engi?m?rpm ?88?0 (tjbee`u?dred?and)eighty`aighv) LLM 解碼 JSON: {'status': 'ERR', 'sensor': 'Engine_rpm', 'value': 3880}	LLM 雖讀懂部分英文拼寫，但因百位數與千位數之語意邊界模糊，導致數值多生成一個位數 (388 變 3880)。

表 5-2 高誤差樣本

綜合上述分析，本系統雖在 $\frac{E_b}{N_0} \geq 3.0 \text{ dB}$ 時具備卓越的泛化與修復能力，但在 1.0 dB 之極端情境下，語言模型對於小數點等微小關鍵字元的敏感度仍是現階段語意通訊面臨之瓶頸。

陸、結論與未來展望

一、系統總結

本研究針對工業物聯網（IIoT）在惡劣物理環境下的數據傳輸痛點，成功開發出一套具備高容錯率之語意通訊系統。有別於傳統過度依賴實體層通道編碼的防護機制，本系統導入了「全域滑動視窗」與「大型語言模型（LLM）」之雙軌語意解碼架構。經過真實世界預測性維護與水質檢測資料集的端到端泛化測試，獲得以下關鍵結論：

1. 跨資料集之免訓練泛化能力：系統無需重新訓練模型，即可透過動態字典載入，適應不同物理特徵之解碼任務。

2. 極端環境下的高可靠度重建：在不具備前向錯誤更正碼（FEC）的條件下，系統於訊雜比 $\frac{E_b}{N_0} = 3.0 \text{ dB}$ 之工作門檻時，即可將平均相對誤差壓低至 0.09 以下，並維持高達 96.3% 之感測器特徵命中率與 100% 的 JSON 格式輸出成功率

3. 幻覺抑制機制之有效性：透過滑動視窗的前置把關與 LLM 的 JSON 格式約束，成功降低了語言模型在處理純數值特徵時的錯誤率。

二、未來研究方向

儘管本系統在對抗實體層雜訊展現了修復能力，但在邁向實際邊緣運算部署時，仍有以下挑戰值得未來進一步探討：

- 1.強化小數點等微小特徵之抗干擾機制：由高誤差樣本分析可知，LLM 對於數值量級（如小數點遺失）仍極為敏感。未來可考慮在語意冗餘編碼階段，加入特定符號權重或數值範圍的提示詞防護，以收斂極端情境下的解碼離群值。
- 2.導入微型語言模型（TinyLMs）：目前採用之 Llama 3 8B 模型雖表現優異，但其運算延遲與記憶體足跡仍不適合部署於資源受限之物聯網端點。未來可探索參數規模更小之專用型語意模型，以滿足即時工業控制之低延遲需求。
- 3.動態冗餘調適機制：未來可整合通道狀態資訊（CSI），使系統能根據當下訊雜比，動態決定將數值轉換為英文字串的「冗餘長度」，以在傳輸可靠度與頻寬效率之間取得最佳平衡。

柒、參考文獻

- [1] Z. Wang *et al.*, "Large-Language-Model Enabled Semantic Communication Systems," *IEEE Transactions on Communications*, 2025.
- [2] Y. Zhang *et al.*, "Multimodal LLM Integrated Semantic Communications for 6G Immersive Experiences," *IEEE Wireless Communications*, 2025.
- [3] S. Kamath *et al.*, "Closing the Semantic-Edge Gap: Tiny Language Models for 6G Wireless Intelligence," *IEEE Internet of Things Journal*, 2026.
- [4] N. Yang, M. Fan, W. Wang, and H. Zhang, "Decision-Making Large Language Model for Wireless Communication: A Comprehensive Survey on Key Techniques," *IEEE Communications Surveys & Tutorials*, vol. 28, 2026.
- [5] H. Xie, Z. Qin, X. Tao, and Z. Han, "Towards Intelligent Communications: Large Model Empowered Semantic Communications," *IEEE Communications Magazine*, vol. 63, no. 1, pp. 69-75, 2024.
- [6] H. Xie, Z. Qin, G. Y. Li, and B.-H. Juang, "Deep Learning Enabled Semantic Communication Systems," *IEEE Transactions on Signal Processing*, vol. 69, pp. 2663-2675, 2021.

附錄：開源資源與實驗可重現性聲明

為確保本專題研究具備嚴謹之學術驗證性與實驗可重現性（Reproducibility），本系統之端到端測試管線、自建訓練資料集，以及量化後之大語言模型權重（Semantic-Decoder.gguf），皆已統整並開源發布。審閱委員與相關研究人員可透過下方連結取得完整專案資源：專案網址：<https://github.com/Boyifu/6G-Semantic-Communication-IoT>